Desarrollo de un Robot Virtual de Asistencia: Fusión Sensorial y Toma de Decisiones Agéntica para la Optimización del Trabajo Cognitivo

1st Roger de Jesús Juárez Mejía
Maestría en Ingeniería en Computación
Universidad Tecnológica de Honduras
Choluteca, Honduras
roger.juarez.rdjjm@gmail.com

***Resumen*—Este documento presenta la propuesta arquitectónica para ATOM, un robot virtual de asistencia diseñado para mitigar la fatiga cognitiva en entornos de desarrollo de software y trabajo intensivo frente a pantallas. El sistema propone una aproximación no invasiva basada en la fusión multimodal de telemetría del sistema operativo y biometría visual en tiempo real (extracción del Eye Aspect Ratio mediante Dlib). Los datos analizados en ventanas ultra-cortas alimentan un núcleo agéntico basado en Modelos de Lenguaje Grande (LLMs). En este contexto, el carácter agéntico de ATOM se define por su capacidad autónoma para evaluar el entorno y ejecutar acciones sobre el espacio físico del usuario, tomando control de los periféricos de audio (Text-to-Speech) para desplegar intervenciones proactivas. Este enfoque desplaza el paradigma de monitorización pasiva hacia una asistencia verdaderamente contextual e inmersiva.**

***Index Terms*—Computación Afectiva, IA Agéntica, Fusión Sensorial, Fatiga Cognitiva, NASA-TLX, Dlib, Text-to-Speech.**

I. Introducción

I-A. Contexto y Relevancia

En la era de la economía digital, el trabajo intensivo frente a pantallas exige niveles sostenidos de atención, lo que frecuentemente desemboca en fatiga cognitiva severa y *burnout*. El desarrollo de herramientas tecnológicas para la preservación del bienestar digital se alinea directamente con los Objetivos de Desarrollo Sostenible (ODS) de las Naciones Unidas, específicamente con el ODS 3 (Salud y Bienestar), al promover la salud ocupacional previniendo el Síndrome Visual Informático [1]; y con el ODS 8 (Trabajo Decente y Crecimiento Económico), al proponer tecnologías que sostienen la productividad sin comprometer la integridad fisiológica del profesional.

I-B. Definición del Problema

La fatiga mental es un proceso progresivo y a menudo imperceptible. Como señala Newport en su teoría del trabajo profundo [2], el cambio de contexto continuo en entornos digitales genera un residuo de atención que acelera el agotamiento. Existe una brecha arquitectónica evidente: la necesidad de un sistema continuo, transparente y que actúe proactivamente antes de que el usuario alcance la fatiga crítica, sin depender de la auto-regulación.

I-C. Contribución

Esta investigación propone el diseño e implementación de una arquitectura de software innovadora que fusiona la percepción sensorial local con el razonamiento de la Inteligencia Artificial Agéntica. La contribución principal reside en la correlación síncrona de la inactividad motora (acciones por minuto del teclado/ratón) y micro-expresiones faciales mediante visión computacional, permitiendo a un LLM detonar intervenciones adaptativas por canales sensoriales no saturados.

II. Estado del Arte y Trabajo Relacionado

II-A. Sistemas de Bienestar Estáticos vs. Dinámicos

Las soluciones comerciales actuales para mitigar la fatiga cognitiva operan predominantemente bajo un paradigma estático. Herramientas de bienestar corporativo o extensiones basadas en la técnica Pomodoro fuerzan pausas en intervalos de tiempo rígidos (ej. interrupciones cada 25 minutos). Estos sistemas ignoran el estado real de *flow* o la carga cognitiva del individuo, lo que a menudo resulta en interrupciones frustrantes y contraproducentes. Por otro lado, la asistencia inteligente comercial carece de consciencia espacial y operativa, funcionando como *chatbots* aislados que requieren que el usuario, ya fatigado, inicie la interacción explícitamente.

II-B. Conexión con la Propuesta

A diferencia de los temporizadores ciegos o enfoques basados en clasificadores de Haar, ATOM implementa alineación facial de alta velocidad mediante árboles de regresión [3], integrado en el predictor de 68 puntos de Dlib. Para la cuantificación estandarizada de la fatiga, el sistema adopta la métrica geométrica del Eye Aspect Ratio (EAR) [4]. A nivel de inferencia lógica, ATOM supera las limitaciones estáticas inyectando el contexto del sistema operativo directamente en el *prompt* del LLM [5], forzando respuestas semánticamente vinculadas a la tarea real del usuario. Esta capacidad de sinergizar el razonamiento contextual con la actuación sobre el entorno físico inscribe a ATOM dentro de los paradigmas modernos de Modelos de Lenguaje Agénticos [6].

III. Arquitectura y Método Propuesto

III-A. Arquitectura Asíncrona de Microservicios

Para garantizar que la captura de video en tiempo real no sufra latencia debido al procesamiento de datos del sistema, la arquitectura de ATOM se diseñó bajo un paradigma de microservicios asíncronos gestionados por un orquestador central (*Watchdog*). Tres subprocesos independientes (telemetría de sistema, biometría visual y motor agéntico) operan en paralelo. El acoplamiento de estos flujos se logra mediante una base de datos local (SQLite) que actúa como puente de sincronización temporal, permitiendo que el motor analice el estado del usuario sin bloquear los hilos de captura.

III-B. Fusión Sensorial Multimodal

El núcleo analítico evalúa el histórico de la base de datos para mitigar la dilución de la señal inherente a los promedios prolongados. Se estableció una ventana de análisis ultra-corta de 5 segundos. La lógica de intervención se rige por una compuerta booleana AND, detonando la fase de razonamiento de la IA únicamente cuando confluyen una caída crítica y sostenida del EAR ($\theta_{EAR} < 0{,}22$) acoplada a una inactividad motora simultánea ($\theta_{APM} < 20$).

III-C. Ingeniería de Instrucciones Contextuales (Prompting) y Delegación (Edge vs. Cloud)

La implementación de LLMs locales (*Edge Computing*) impone una sobrecarga que degrada los FPS necesarios para el cálculo del EAR. Por ello, ATOM delega el razonamiento heurístico a la API de OpenAI (modelo *gpt-4o-mini*). El puente entre la telemetría y el lenguaje natural se construye mediante una inyección de contexto dinámica: el sistema extrae el título exacto de la ventana en foco y lo incrusta en una instrucción sistémica estructurada. Esta técnica de *Prompt Engineering* garantiza que la salida sea concisa (máximo 30 palabras) y altamente relevante a la tarea actual.

III-D. Intervención Agéntica Auditiva (TTS)

De acuerdo con la Teoría de Recursos Múltiples propuesta por Wickens [7], presentar información visual a un usuario que ya experimenta fatiga óptica eleva la carga cognitiva global. Como acción agéntica sobre el entorno físico, el sistema sintetiza la respuesta generada por la API utilizando un motor *Text-to-Speech* (TTS) nativo y notificaciones asíncronas del sistema operativo. Esto transforma a ATOM en un asistente inmersivo que no exige desviar la atención visual del usuario para recibir retroalimentación.

IV. Resultados Preliminares

IV-A. Rendimiento y Sobrecarga del Sistema

Las pruebas empíricas del prototipo demostraron la viabilidad de la arquitectura híbrida. La orquestación mediante SQLite permitió que la recolección de telemetría mantuviera una huella de memoria inferior a 150 MB. Asimismo, la latencia de extremo a extremo (*End-to-End Latency*)—medida desde el cumplimiento de la compuerta lógica AND hasta la síntesis de voz—se mantuvo en un promedio sub-óptimo de 2.1 segundos, demostrando que la delegación a la nube no compromete la intervención en tiempo real.

IV-B. Viabilidad Económica (Tokenomics)

El uso del modelo *gpt-4o-mini* demostró ser escalable. Con un costo de \$0.15 USD por millón de *tokens*, y un consumo promedio de 60 *tokens* por alerta, el costo operativo por jornada laboral se calcula en fracciones de centavo ($< \$0{,}01$ USD). Esta métrica ratifica que la arquitectura es comercialmente viable como solución de Software como Servicio (SaaS).

IV-C. Impacto Fisiológico (Resultados en Proceso)

[Nota: En esta subsección se incluirá el análisis del Delta de Recuperación, comparando el EAR promedio 3 minutos antes y 3 minutos después de la intervención agéntica, una vez finalizada la fase actual de recolección de datos empíricos.]

V. Discusión y Trabajo Futuro

V-A. Casos Límite: Iluminación y Fatiga Activa

Durante el periodo de validación, se comprobó una degradación en la fiabilidad del clasificador HOG al operar en entornos con temas oscuros (*Dark Mode*), donde la baja luminiscencia del monitor reduce el contraste palpebral. Adicionalmente, se documentó el fenómeno de "Fatiga Motora Inercial", donde el usuario presenta agotamiento ocular clínico ($EAR < 0{,}18$) manteniendo un ritmo sostenido de tipeo ($APM > 40$). Estos hallazgos validan la decisión de utilizar una compuerta AND restrictiva para mitigar interrupciones invasivas.

V-B. Validación Subjetiva (NASA-TLX) e Integración RAG

Como trabajo futuro para establecer el *ground truth* fisiológico de los umbrales propuestos, se proyecta la implementación del índice estandarizado NASA-TLX (*Task Load Index*) [8] al final de las sesiones de prueba. La correlación entre la telemetría y la percepción subjetiva de carga mental permitirá refinar el modelo predictivo. Asimismo, para mitigar las alucinaciones inherentes a los LLMs y dotar al sistema de consciencia médica, se propone la integración de bases de datos vectoriales locales para implementar técnicas de Generación Aumentada por Recuperación (RAG) [9]. Esto dotará a ATOM de una memoria semántica y conocimientos clínicos específicos sobre salud ocupacional.

Referencias

[1] M. Rosenfield, "Computer vision syndrome: a review of ocular causes and potential treatments," *Ophthalmic and Physiological Optics*, vol. 31, no. 5, pp. 502–515, 2011.

[2] C. Newport, *Deep Work: Rules for Focused Success in a Distracted World*. Grand Central Publishing, 2016.

[3] V. Kazemi and J. Sullivan, "One millisecond face alignment with an ensemble of regression trees," in *CVPR*, 2014, pp. 1867–1874.

[4] T. Soukupová and J. Čech, "Real-time eye blink detection using facial landmarks," in *21st Computer Vision Winter Workshop (CVWW)*, 2016.

[5] OpenAI, "Gpt-4 technical report," *arXiv preprint arXiv:2303.08774*, 2023.

[6] S. Yao, J. Zhao, D. Yu, N. Du, I. Shafran, K. Narasimhan, and Y. Cao, "React: Synergizing reasoning and acting in language models," *arXiv preprint arXiv:2210.03629*, 2022.

[7] C. D. Wickens, "Multiple resources and mental workload," *Human factors*, vol. 50, no. 3, pp. 449–455, 2008.

[8] S. G. Hart and L. E. Staveland, "Development of nasa-tlx (task load index): Results of empirical and theoretical research," in *Advances in psychology*. Elsevier, 1988, vol. 52, pp. 139–183.

[9] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel *et al.*, "Retrieval-augmented generation for knowledge-intensive nlp tasks," *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474, 2020.